1 Stat-DSM

Tujuan utama dari Stat-DSM adalah jika diberikan dua kelompok lintasan, Stat-DSM ingin untuk menemukan pola pergerakan dalam bentuk sub-lintasan yang lebih mirip dengan sub-lintasan di satu kelompok, namun kurang mirip dengan sub-lintasan di kelompok lainnya. Stat-DSM ingin memisahkan dua kelas lintasan dimana setiap sub-lintasan pada setiap kelas memiliki perbedaan yang cukup sehingga dapat dinyatakan bahwa perbedaan tersebut merupakan signifikan secara statistik dan tidak terjadi hanyak karena acak.

2 Lintasan

Sebuah lintasan diisi dengan kumpulan titik yang bersifat kontinu $T_i = (p_i^1, p_i^2, ..., p_i^n)$. Dengan setiap titik dinotasikan dengan $p_i^t = (x_i^t, y_i^t)$ yang merupakan koordinat x dan y dari setiap titik pada waktu. Setiap lintasan memiliki kelas atau label $Y_i \in \{0, 1\}$ dimana $Y_i = 1$ menandakan sukses dan $Y_i = 0$ menandakan tidak sukses.

3 Sub-Lintasan

Sub-lintasan adalah bagian kontinu dari suatu lintasan. Anggap kita memiliki sebuah lintasan

$$T_i = (p_i^1, p_i^2, p_i^3, p_i^4, p_i^5, p_i^6, p_i^7, p_i^8)$$

sebuah sub-lintasan dapat berupa $S_i = (p_i^3, p_i^4, p_i^5, p_i^6, p_i^7)$.

4 Distance Function

Pada Stat-DSM, distance function dipergunakan untuk mencari kemiripan antar dua sub-lintasan. Algoritma melakukan ini dengan cara membandingkan jarak koordinat antar dua sub-lintasan. Algoritma pertama mencari sub-lintasan yang sama dengan menggunakan euclidean distance untuk mencari jarak antar dua titik. Anggap kita memiliki dua titik yaitu (x_1, y_1) dan (x_2, y_2), maka

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Lalu setelah setiap titik dicari euclidean ditance masing-masing, algoritma akan mengurut hasilnya dari yang peling besar hingga yang paling kecil. Setelah diurut, kita akan menggunakan paramater K untuk menentukan menggunakan berapa distance terbesar untuk kalkulasi selanjutnya yaitu menggunakan

$$\text{dist}_K(A, B) = \frac{1}{K} \sum_{k=1}^{K} d^{(k)}$$

yang berarti jika $K = 1$, maka ambil euclidean distance yang terbesar, dan jika diatas 1 maka contohnya adalah $K = 2$ maka ambil 2 euclidean distance terbesar, tambahkan keduanya dan bagi dengan K

5 Contingency Table

Sebuah tabel dalam format matriks yang menampilkan distribusi frekuensi dari dua variabel kategorikal atau lebih. Anggap kita menemukan untuk label kelas positif 80 mengandung S dan 20 tidak dan untuk label kelas negatif 30 mengandung S dan 70 tidak. Sehingga didapatkannya

Tabel 1: A 2×2 Contingency Table

	Mengandung		
Kelas	S	$\neg S$	**Total**
Positif	80	20	100
Negatif	30	70	100
Total	110	90	200

6 Fisher's Exact Test

Fisher's Exact Test merupakan sebuah metode untuk memeriksa apakah terdapat asosiasi (hubungan atau ketergantungan) yang signifikan antara dua variabel kategorikal. Dengan menggunakan contingency table

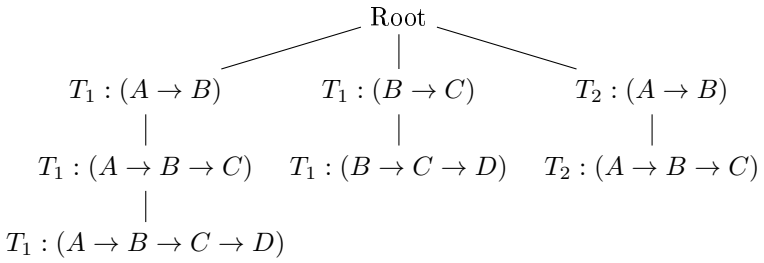
Label	S	$\neg S$
Positif	a	b
Negatif	c	d

Dapat ditarik probabilitas mendapatkan data tersebut murni sebagai kebetulan dengan

$$p\text{-value} = \frac{\binom{a+b}{a}\binom{c+d}{c}}{\binom{a+b+c+d}{a+c}}$$

7 Candidate Tree

Pohon yang mengandung sub-lintasan yang akan diproses. Setiap node pertama pada branch diisi dengan sub-lintasan ukuran min_l dengan node dibawahnya merupakan sebuah perpanjangan sub-lintasan tersebut. Penelusuran pohon dilakukan secara Depth-First-Search, yang berarti algoritma memproses sebuah sub-lintasan dengan ukuran min_l dan mencoba untuk memperpanjang sub-lintasan tersebut sampai tidak bisa lagi atau p-value lebih besar dari threshold lalu lanjut ke sub-lintasan panjang min_l lainnya. Selama penelusuran pohon, dilakukan pula koreksi terhadap threshold dan threshold tersebut kemudian digunakan untuk menentukan branch mana dan di bagian mana pada pohon yang dapat di *prune* Contoh candidate tree :



Gambar 1: Contoh *Candidate Tree*

8 Westfall-Young Permutation Correction Method

Sebuah metode statistik untuk menyesuaikan threshold yang digunakan ketika melakukan pengujian hipotesis pada ribuan hingga jutaan kandidat sub-lintasan secara bersamaan. Cara kerjanya dalam algoritma Stat-DSM adalah pertama terdapat list p-value terkecil untuk setiap permutasi dari antara seluruh node. List tersebut berupa array dengan setiap index pada array tersebut dibedakan berdasarkan cara permutasi yang berbeda-beda untuk label dan isinya merupakan p-value terkecil untuk permutasi tersebut. List array ini akan dinotasikan sebagai $p_min(b)$ dimana b merupakan index dari array tersebut. Kemudian pada setiap

perhitungan node pada tree, akan dilakukan kalkulasi seluruh index b pada p_min yang pertama melihat apakah pada $p_min(b)$ nilai p-value lebih besar dari nilai p-value dari node yang sekarang lagi diproses dan jika iya, maka lakukan perhitungan p-value menggunakan permutasi yang sama dan jika didapatkan p-value lebih kecil dari pada $p_min(b)$ maka ubah isi $p_min(b)$ menjadi nilai p-value dari permutasi tersebut.

9 Input

Input dari Stat-DSM meliputi

1. T yang merupakan dataset lintasan
2. g yang merupakan label untuk dataset lintasan
3. ε atau distance threshold untuk kalkulasi distance
4. min_l untuk menentukan panjang minimum sebuah sub-lintasan
5. K atau Top-K-Max yang menentukan berapa nilai yang diambil untuk menghitung distance
6. B untuk membatas jumlah permutasi dari label untuk metode Westfall-Young.
7. α atau target significance level untuk melihat sub-lintasan mana yang tidak memiliki nilai p-value yang cukup

10 Output

Output dari Stat-DSM merupakan nilai significance level yang sudah dikoreksi $\delta*$, list p-value dari semua sub-lintasan tersebut dan juga tabel sub-lintasan yang memiliki p-value $< \delta*$ dengan tabel tersebut mengandung id dan titik-titik dari sub-lintasan tersebut.

11 Test Case

11.1 Input

Tabel 2: T Lintasan dengan g Label

TID	Label	Point 0	Point 1	Point 2
0	0	(0, 0)	(1, 0)	(2, 0)
1	1	(0.1, 0)	(1.1, 0)	(2.1, 0)
2	1	(0, 0.1)	(1, 0.1)	(2, 0.1)
3	0	(10, 12)	(11, 12)	(12, 12)

1. $\varepsilon = 0.5$
2. $min_l = 2$
3. $K = 1$
4. $B = 4$
5. $\alpha = 0.05$

11.2 Processing Awal

11.2.1 Buat permutasi label

Karena $B = 4$, akan dibuat 4 permutasi dari label original. Contoh :

Permutasi ke-	$T0$	$T1$	$T2$	$T3$
1	0	0	1	1
2	0	1	0	1
3	1	0	0	1
4	1	0	1	0

11.2.2 Hitung jumlah lintasan pada masing-masing kelas label

Untuk label positif $N_+ = 2$, untuk label negatif $N_- = 2$.

11.2.3 Buat array list_min_p

Buat array list_min_p dengan ukuran B untuk diisi dengan kumpulan p-value terkecil untuk setiap permutasi. Awal-awal isi seluruh array dengan α yaitu 0.5.

11.3 Kalkulasi Stat-DSM

11.3.1 Generate kandidat pertama

$S_{1,2}^{T0} = (0,0) \rightarrow (1,0)$

11.3.2 Cari lintasan yang mirip

Contoh bandingkan antara kandidat pertama

$$A = (0,0) \rightarrow (1,0)$$

dengan sub-lintasan dari $T1$

$$B = (0.1,0) \rightarrow (1.1,0)$$

Menggunakan euclidean distance didapatkan :

$$d_1 = \sqrt{(0-0.1)^2 + (0-0)^2}$$

$$d_1 = 0.1$$

dan

$$d_2 = \sqrt{(1-1.1)^2 + (0-0)^2}$$

$$d_2 = 0.1$$

Dan karena $K = 1$ sehingga mengambil distance terbesar diantara keduanya

$$dist_1(A,B) = \max(0.1, 0.1) = 0.1$$

Dan karena $\varepsilon = 0.5$ dan $0.1 \leq 0.5$ sehingga algoritma menanggap A mirip dengan B

Lakukan hal yang sama untuk semua sub-lintasan yang ditemukan seperti dari $T1$ masih terdapat $(1.1,0) \rightarrow (2.1,0)$ dan juga pada $T2$ terdapat $(0,0.1) \rightarrow (1,0.1)$ dan $(1,0.1) \rightarrow (2,0.1)$ dan lain-lainnya untuk setiap lintasan. Anggap didapatkannya :

Tabel 3: Hasil Evaluasi Jarak Batas (Threshold)

TID	Calculated distance	Threshold	Accepted?
$S^{T1}_{1,2}$	0.1	0.5	Yes
$S^{T1}_{2,3}$	2.1	0.5	No
$S^{T2}_{1,2}$	0.1	0.5	Yes
$S^{T2}_{2,3}$	1.005	0.5	No
$S^{T3}_{1,2}$	Far greater than 0.5	0.5	No
$S^{T3}_{2,3}$	Far greater than 0.5	0.5	No

11.3.3 Kalkulasi Lower Bound

Setelah mendapatkan semua sub-lintasan yang mirip dengan S^{T0}_1, kita perlu menghitung lower bound dari sub-lintasan tersebut untuk melihat apakah memperpanjang branch ini diperlukan. Dimiliki support $= 4, N_+ = 2, N_- = 2$ sehingga didapat Upper lower bound :

$$LB_U = \frac{\binom{2}{2}\binom{2}{0}}{\binom{4}{2}}$$

$$LB_U = 0.1667$$

dan Lower lower bound :

$$LB_L = \frac{\binom{2}{0}\binom{2}{2}}{\binom{4}{2}}$$

$$LB_L = 0.1667$$

dan final lower bound didapat sebagai :

$$LB = min(LB_U, LB_L)$$

$$LB = 0.1667$$

11.3.4 Pruning

Pada bagian ini akan digunakannya list_min_p $= [0.05, 0.05, 0.05, 0.05]$ dan parameter $B = 4$ dan $\alpha = 0.05$ untuk mendapatkan $idx = \lfloor B\alpha \rfloor$

$$idx = \lfloor 4 * 0.05 \rfloor$$

$$idx = 0$$

Sehingga untuk pruning, akan digunakannya list_min_p yang di sort terlebih dahulu untuk mendapatkan sorted_list_min_p. Dan mengambil

$$sorted_list_min_p[0] = 0.05$$

Karena $0.05 \leq 0.1667$, maka untuk branch S_1T0 dapat di prune karena branch tidak dapat membuat p-value yang cukup rendah.

12 Test Case 2

12.1 Input

12.1.1 Dataset

Tabel 4: Data Koordinat Berdasarkan TID dan Label

TID	Label	Point 0	Point 1	Point 2
0	0	(0, 0)	(1, 0)	(2, 0)
1	1	(0.1, 0)	(1.1, 0)	(2.1, 0)
2	1	(0, 0.1)	(1, 0.1)	(2, 0.1)
3	1	(0, -0.1)	(1, -0.1)	(2, -0.1)
4	1	(0.1, 0.1)	(1.1, 0.1)	(2.1, 0.1)
5	0	(10, 10)	(11, 10)	(12, 10)
6	0	(10, 11)	(11, 11)	(12, 11)
7	0	(10, 12)	(11, 12)	(12, 12)

12.1.2 Parameters

1. $\varepsilon = 0.5$
2. $min_l = 2$
3. $K = 1$
4. $B = 1000$
5. $\alpha = 0.05$

12.2 Initial Processing

$$N_+ = 4, N_- = 4$$

$$list_min_p = [0.05] * 1000$$

Permutations :

Permutasi ke-	$T0$	$T1$	$T2$	$T3$	$T4$	$T5$	$T6$	$T7$
1	1	0	0	0	0	1	1	1
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
1000	0	1	0	0	1	1	1	0

12.3 Kalkulasi Stat-DSM

Anggap kandidat pertama merupakan $S_1^{T0} = (0,0) \rightarrow (1,0)$
Anggap kita mendapatkan lintasan yang mirip merupakan lintasan

$$[T1, T2, T3, T4]$$

12.4 Hitung lower bound & pruning

Upper lower bound :

$$LB_U = \frac{\binom{4}{4}\binom{4}{0}}{\binom{8}{4}}$$

$$LB_U = \frac{1}{70} = 0.014286$$

Lower lower bound :

$$LB_L = \frac{\binom{4}{0}\binom{4}{4}}{\binom{8}{4}}$$

$$LB_L = \frac{1}{70} = 0.014286$$

Final lower bound :

$$LB = 0.014286$$

Dan bandingkan dengan α

$$0.014286 < 0.05$$

Lolos pruning

12.5 Update list_min_p

12.5.1 Menghitung p-value kandidat dengan label original

Upper p-value :

$$P(X \geq 4) = \frac{\binom{4}{4}\binom{4}{0}}{\binom{8}{4}}$$

$$P(X \geq 4) = \frac{1}{70} = 0.014286$$

dan Lower p-value :

$$P(X \leq 4) = 1$$

sehingga two sided p-value :

$$p = \min(1, 2 \times \min(P_{upper}, P_{lower}))$$

$$p = 2 \times 0.014286$$

$$p = 0.028571$$

12.5.2 Permutation testing

Pada bagian ini hanya akan dilakukan perhitungan untuk 5 permutasi, pada nyatanya dapat dilakukan lebih. Seharusnya akan dilakukan

$$B = \binom{8}{4} = 70 \text{ permutasi}$$

Sub-lintasan S_1^{T0} memiliki kemiripan dengan $T = [1, 2, 3, 4]$.
Anggap $X =$ jumlah tetangga(lintasan dengan kemiripan dengan sub-lintasan) dengan label positif Anggap didapati :

Tabel 5: Permutasi Data Table

Permutasi	T0	T1	T2	T3	T4	T5	T6	T7	X
P1	0	1	1	1	1	0	0	0	4
P2	1	0	0	0	0	1	1	1	0
P3	0	1	0	1	0	1	0	1	2
P4	1	1	0	1	0	0	1	0	2
P5	0	1	1	1	0	1	0	0	3

Sehingga kita dapat menghitung p-value dengan menggunakan

$$P(X = x) = \frac{\binom{4}{x}\binom{4}{4-x}}{\binom{8}{4}}$$

Dan hasilnya :

X	Perhitungan	Jumlah kemungkinan
0	$\binom{4}{0}\binom{4}{4}$	1
1	$\binom{4}{1}\binom{4}{3}$	16
2	$\binom{4}{2}\binom{4}{2}$	36
3	$\binom{4}{3}\binom{4}{1}$	16
4	$\binom{4}{4}\binom{4}{0}$	1

Tabel 6: Tabel Distribusi Kemungkinan X

Selanjutnya harus dihitung upper-p-value dan lower-p-value Didapatkan :

X	Upper-tail probability	Lower-tail probability
0	1	1/70
1	69/70	17/70
2	53/70	53/70
3	17/70	69/70
4	1/70	1

Tabel 7: Tabel Probabilitas Ekor Atas dan Ekor Bawah

dan kemudian dapat dihitung p-value menggunakan rumus

$$p = \min(1, 2 \times \min(P_{upper}, P_{lower}))$$

sehingga didapatkan nilai

Tabel 8: Tabel Nilai P-value dan Jumlah Permutasi

X	Two-sided p-value	Jumlah permutasi
0	0.028571	1
1	0.485714	16
2	1.000000	36
3	0.485714	16
4	0.028571	1

12.5.3 Ubah list_min_p

Yang awalnya isi $list_min_p = [0.05] * 1000$ Kita akan mengubah semua nilai pada list_min_p yang memiliki angka yang lebih besar dibandingkan nilai Two-sided p-value yang kita bru hitung Sehingga sekarang $list_min_p = [0.028571, 0.05, 0.05, 0.05, 0.028571, \ldots, 0.05]$

12.6 Adjusted Significance Threshold

Selanjutnya untuk mendapatkan significance threshold yang telah di adjust perlu dihitung

$$\delta* = \lfloor B\alpha \rfloor$$

Angka $\delta*$ kemudian akan merujuk kepada sorted_list_min_p sebagai index, dan value pada array tersebutlah menjadi adjusted significance threshold baru

12.7 Loop

Lakukan hal yang sama lagi dari atas dengan kandidat yang lain namun sorted_list_min_p menggunakan yang baru